

Pre Entrega Módulo 5 — Agente con Conocimiento Organizacional

Alumno/a: S. Maureira · Continuación del Checkpoint 1 (Agente de Calificación de Leads en n8n) · Empresa cliente: Nexo Digital S.A. (NexoCRM)

El agente del Checkpoint 1 (Chat Trigger → AI Agent en modo Tools Agent → Google Sheets + log en Gmail) se amplió con conocimiento organizacional: ahora responde dudas de los potenciales clientes a partir del manual comercial parseado con LlamaParse e indexado en una base vectorial, y sigue registrando los leads calificados.

1 Documento parseado en LlamaCloud (LlamaParse)

[Captura 1] Pegá acá la captura de LlamaCloud → Parse → Results (vista Markdown), con el PDF a la izquierda y, a la derecha, los títulos # / ## y la tabla §2.1 Planes renderizada como celdas.

LlamaCloud → Parse (tier Agentic): el PDF original a la izquierda y su versión Markdown a la derecha, con la jerarquía de títulos y las tablas interpretadas como celdas.

Documento elegido y preparación

Después de auditar la documentación del cliente, elegí como archivo maestro el **“Manual de Políticas Comerciales y FAQ v3.1”** de Nexo Digital (10 secciones, 5 tablas: planes y precios, medios de pago, plazos de implementación, SLA de soporte e integraciones), porque concentra todo lo que preguntan los leads que atiende el agente. Lo preparé “limpio” para el parseador: **sin** encabezados ni pies de página repetidos, sin logos ni cuadros decorativos, con las tablas como tablas reales (no imágenes ni celdas combinadas) y con una numeración de títulos uniforme (1 → 1.1) para que se conserve la jerarquía.

Parseo y chunking

Parámetro	Valor	Por qué
Parser	LlamaParse, tier Agentic , salida Markdown	Conserva los títulos como #/##/### y convierte las tablas en tablas Markdown (celda por celda). Costo: 60 créditos de 10.000 del plan gratuito.
Chunking	Recursive Character Text Splitter con Split Code = markdown : 2.000 caracteres (~512 tokens), overlap 250 (~64 tokens)	Chunking semántico: corta primero por títulos ##/### y recién después por párrafos, así cada subsección (ej. §7.3) queda con su título y las tablas no se cortan a la mitad.
Embeddings	Google Gemini (gemini-embedding-001)	Buen rendimiento en español y capa gratuita.

Evaluación del resultado de LlamaParse

LlamaParse extrajo el texto completo y leyó las 5 tablas como celdas (salida en tablas HTML, fila por fila). Al revisar el Markdown contra el PDF original encontré cuatro problemas que afectan directamente al chunking:

Hallazgo	Impacto en el RAG	Corrección aplicada
Tablas intercambiadas: bajo §2.1 “Tabla de planes” quedó la tabla de medios de pago, y la de planes quedó bajo §3.2 “Pago en cuotas”; §3.1 quedó vacía.	Grave: la pregunta “¿cuánto sale el plan Pro?” recuperaría un chunk titulado “Tabla de planes” con medios de pago, y los precios quedarían asociados a “cuotas”.	Cada tabla se devolvió a su sección, verificado contra el PDF.
Jerarquía de títulos inconsistente: el título salió como ##, las secciones 1-2 como ###/####, de la 3 en adelante como ##/###, y §5.2-5.3 subieron a ##.	Medio: el splitter corta por títulos, así que §5.2 y §5.3 quedarían como capítulos separados de la §5.	Niveles normalizados: # título, ## capítulo, ### subsección.
Negritas en títulos (## **7. . . **) de la sección 7 a la 10.	Bajo: ruido en el texto del chunk.	Se quitaron los **.
Números de página sueltos (“1 / 6”, “2 / 6”...).	Bajo: ruido que puede caer en medio de un chunk.	Se eliminaron.

Conclusión: el parseador **preservó las celdas pero no siempre la posición ni la jerarquía**. Por eso la revisión humana del Markdown antes de indexar es un paso obligatorio del proceso (ver gobernanza). Archivos: Manual_Comercial_LlamaParse_original.md (salida cruda) y Manual_Comercial_parseado.md (versión corregida que se indexó).

Decisión de arquitectura: en el plan gratuito actual de LlamaCloud, la creación de *Index* requiere plan Starter y el plan Free permite 0 *Data Sources* (“This feature requires a Starter, Pro, or Enterprise plan”). Por eso usé LlamaCloud para la etapa crítica, el **parseo**, y cargué el Markdown resultante en el **Simple Vector Store** de n8n mediante un formulario de carga. El flujo RAG es el mismo: parseo → chunking → embeddings → recuperación como herramienta del agente.

2 Vector Store Retrieve Tool: Top-K y Minimum Score

[Captura 2] Pegá acá la captura del nodo Simple Vector Store en modo Retrieve Documents (As Tool for AI Agent), acoplado al AI Agent, donde se lean: nombre **consultar_manual_comercial**, la descripción, la memory key **manual_nexo_v3_1** y **Limit (Top-K) = 4**.

Nodo consultar_manual_comercial (Simple Vector Store, modo herramienta) conectado a la base manual_nexo_v3_1.

Campo	Valor configurado
Nombre (tool name)	consultar_manual_comercial
Descripción de negocio	“Busca en el Manual de Políticas Comerciales y FAQ v3.1 de Nexo Digital (parseado con LlamaParse e indexado en la base vectorial). Usala SIEMPRE que el usuario pregunte por planes, precios, usuarios, medios de pago, cuotas, descuentos, facturación, prueba gratuita, demos, implementación, migración, capacitación, soporte, SLA, tiempos de respuesta, cancelación, reembolsos, derecho de arrepentimiento, seguridad de datos, integraciones, API o app móvil de NexoCRM. NO la uses para registrar leads ni para saludos o charla general.”
Base vectorial	manual_nexo_v3_1 (la misma memory key que usa el formulario de carga; verificado antes de seguir)
Top-K (Limit)	4
Minimum Score	0.55 (valor objetivo; ver limitación)

Justificación del balance precisión / costo

Top-K = 4: con chunks de ~512 tokens, 4 fragmentos suman unos ~2.000 tokens de contexto por consulta. **Medido en n8n**, cada ciclo del agente (system prompt + definición de herramientas + 4 fragmentos) consume **~5.200 tokens**, y en una misma respuesta el agente llamó a la herramienta 2 veces. Con el límite de 8.000 tokens/minuto de la capa gratuita de Groq, un Top-K = 8 haría inviable responder siquiera una pregunta por minuto. Bajar a 1-2 deja afuera la información que está repartida entre dos secciones (ej. precio en §2.1 + cuotas en §3.2); subir a 8 duplica el costo y mete chunks de temas vecinos que empujan al modelo a mezclar políticas.

Minimum Score = 0.55: es el umbral que fijaría en un índice gestionado (LlamaCloud Index, Pinecone o Supabase): los chunks pertinentes suelen puntuar por encima de 0.6 y los de temas vecinos entre 0.4 y 0.5, así que 0.55 descarta ruido sin cortar preguntas informales válidas (≥ 0.7 sería demasiado estricto). **Limitación:** el Simple Vector Store de n8n no expone un control de score mínimo y siempre devuelve los 4 fragmentos más cercanos. Lo compensé en el System Prompt: el agente solo puede responder si el fragmento contiene el dato exacto y, si no, debe decir “No sé”. Al migrar a un índice pago, el umbral se aplica en la herramienta y el control deja de depender del modelo.

3 Estructura del System Prompt RAG

[Captura 3] Pegá acá la captura del AI Agent → Options → System Message, donde se lean las secciones **FUENTE ÚNICA DE VERDAD** (citar fuentes) y **REGLA DORADA DE CONTINGENCIA: No sé.**

System Message del AI Agent (modo Tools Agent).

Estructura: **Rol → Fuente única de verdad (100 % basado en fragmentos + formato de cita) → Regla dorada “No sé” → Calificación de leads (heredado del Checkpoint 1) → Límites y escalamiento.** Texto completo de las dos reglas evaluadas:

```
# FUENTE ÚNICA DE VERDAD (RAG)
- Tu ÚNICA fuente de información sobre la empresa es el "Manual de Políticas Comerciales y FAQ v3.1",
  al que accedés con la herramienta `consultar_manual_comercial`.
- ANTES de responder cualquier pregunta sobre planes, precios, pagos, cuotas, prueba gratuita,
  implementación,
  soporte, cancelaciones, reembolsos, seguridad o integraciones, SIEMPRE llamá a
  `consultar_manual_comercial`.
  Si el usuario usa palabras informales o sinónimos ("la guita", "darme de baja", "se cae el sistema"),
  reformulá la búsqueda con el vocabulario formal del manual (reembolso, cancelación, incidente crítico).
- Basá tus respuestas al 100% en los fragmentos que devuelve la herramienta. Está PROHIBIDO usar tu
  conocimiento general, suponer, redondear, extrapolar o combinar datos que no estén escritos en los
  fragmentos.
- Citá SIEMPRE la fuente al final de cada dato con el formato: (Fuente: Manual Comercial v3.1, §<número de
  sección>).
```

```
# REGLA DORADA DE CONTINGENCIA: "No sé"
- Si la herramienta no devuelve fragmentos, o si los fragmentos no contienen el dato exacto que se
  preguntó,
  respondé textualmente y únicamente: "No sé."
- No agregues explicaciones, disculpas, sugerencias ni ningún otro texto antes o después de "No sé."
- Nunca reemplaces el "No sé" por una estimación, una respuesta parcial inventada o información de otra
  sección que "se parece".
- Si el fragmento recuperado habla de un tema parecido pero NO del que se preguntó (por ejemplo:
  cancelación vs.
  derecho de arrepentimiento), volvé a consultar la herramienta con otros términos; si sigue sin aparecer,
  respondé "No sé".
```

El cerebro del agente es el **Google Gemini Chat Model** (gemini-2.5-flash) con **temperature = 0**, para reducir la variación entre corridas y que se ciña a los fragmentos. Empecé con Groq (openai/gpt-oss-120b), pero la capa gratuita corta en 8.000 tokens por minuto y el agente necesita ~5.200 por ciclo, así que la respuesta final fallaba con *"Rate limit reached"*; lo reemplacé por Gemini, que usa la misma credencial que los embeddings.

4 Reporte de validación: 5 preguntas ciegas

Las preguntas se hicieron desde el chat público del Chat Trigger, con vocabulario informal y sinónimos que **no** aparecen literalmente en el manual. En cada caso revisé en la ejecución de n8n que el agente pasara por la rama de consultar_manual_comercial (nodo en verde) y qué fragmentos devolvió.

#	Pregunta (sinónimo / informal)	Fragmento recuperado	Respuesta del agente	Veredicto
1	"Somos 10 en el equipo, ¿cuánto nos sale por mes?"	§2.1 Tabla de planes: "Pro Hasta 15 79 806 Hasta 20.000 Email y chat"	"Para 10 personas te corresponde el plan Pro (hasta 15 usuarios): USD 79 por mes, o USD 806 en pago anual. (Fuente: Manual Comercial v3.1, §2.1)"	✅ Correcto (leyó bien la celda de la tabla y citó la fuente)
2	"¿Lo puedo probar de onda sin poner la tarjeta?"	§4.1 Prueba gratuita: "prueba gratuita de 14 días corridos ... No se solicita tarjeta de crédito"	"Sí, tenés 14 días corridos de prueba gratis con todas las funciones de Business y no te piden tarjeta. (Fuente: Manual Comercial v3.1, §4.1)"	✅ Correcto
3	"Tengo el plan Pro, si se me cae todo un sábado, ¿en cuánto me atienden?"	§6.2 SLA: "Crítica ... 4 h hábiles" + "En Starter y Pro los incidentes reportados un fin de semana se empiezan a contar desde el lunes a las 9:00."	"En Pro, un incidente crítico tiene respuesta en 4 horas hábiles, pero si lo reportás un sábado el plazo empieza a contar el lunes a las 9:00. (Fuente: Manual Comercial v3.1, §6.2)"	✅ Correcto (combinó la celda de la tabla con la nota aclaratoria)
4	"¿Se puede enchufar con SAP?"	§9.1 Integraciones nativas (la tabla no menciona SAP)	"No sé."	✅ Correcto (aplicó la regla "No sé" y no inventó la integración)
5	"Pagué el anual ayer y me arrepentí, ¿me devuelven la guita?"	Recuperó §7.1 Cancelación y §7.2 Reembolso de planes anuales ("se le reembolsa el 70 % de los meses completos no utilizados"). No recuperó §7.3 Derecho de arrepentimiento.	"Si cancelás el plan anual se te reembolsa el 70 % de los meses no utilizados. (Fuente: Manual Comercial v3.1, §7.2)"	⚠️ Falla de recuperación: correspondía el 100 % por arrepentimiento dentro de los 10 días (§7.3)

4 / 5 (80 %)

Precisión de respuesta

5 / 5 (100 %)

Activación de la herramienta RAG

1 / 1

Casos "No sé" bien aplicados

0

Alucinaciones fuera del manual

Análisis crítico de la falla (caso 5)

- **Qué pasó:** el agente activó bien la herramienta y citó una fuente real, así que no es una alucinación. El error estuvo en la **recuperación**: "me devuelven la guita" se parece mucho más, semánticamente, a la palabra "reembolsa" de §7.2 que a "revocar la contratación" de §7.3. El chunk de arrepentimiento quedó fuera de los 4 más cercanos (Top-K) y el modelo respondió con el fragmento "parecido".
- **Por qué es grave:** la respuesta es incorrecta a nivel legal (Ley 24.240) y económico: el cliente tiene derecho al 100 %, no al 70 %.

- **Acciones correctivas:** (1) reescribir el título de §7.3 en el documento fuente como “Derecho de arrepentimiento (devolución del 100 % del dinero dentro de 10 días)”, para que el chunk contenga el vocabulario de “devolver la plata”; (2) sumar un **reranker** (por ejemplo Cohere Rerank, disponible en n8n) que reordene un Top-K inicial de 8 y se quede con los 4 mejores, para que el reordenamiento distinga “arrepentimiento” de “cancelación”; (3) mantener en el prompt la instrucción de volver a consultar cuando el fragmento trate un tema vecino. Después de aplicar (1), el caso 5 se vuelve a correr en la próxima batería.
- **Observación sobre el caso 3:** fue correcto porque la nota sobre fines de semana quedó en el mismo chunk que la tabla. Eso confirma que conviene no bajar el tamaño de chunk por debajo de 512 tokens.

5 Plan de gobernanza de la base de conocimiento

Roles y responsables

Rol	Quién	Responsabilidad
Dueño del contenido	Gerencia Comercial de Nexo Digital	Aprueba cada versión del manual y es el único que autoriza cambios de precios, planes o políticas.
Curador de la base / administrador del agente	S. Maureira (equipo de automatización)	Parsea los documentos en LlamaCloud (LlamaParse), revisa el Markdown contra el original (posición de tablas, niveles de títulos, ruido), lo carga en la base vectorial con el formulario, mantiene Top-K / Minimum Score y corre la batería de validación.
Validador legal	Asesoría legal externa	Revisa las secciones 7 (arrepentimiento y reembolsos) y 8 (datos personales) cada vez que cambian.

Frecuencia de revisión

Cuándo	Qué se hace
Mensual (primer día hábil)	Se verifica que la versión indexada coincida con la vigente (fecha de “Próxima revisión” del encabezado). Se corre la batería de las 5 preguntas ciegas más las preguntas reales del mes que terminaron en “No sé”. Meta: precisión $\geq 80\%$ y 0 alucinaciones.
Por evento (en 48 h hábiles)	Ante un cambio de precios, un plan nuevo, una nueva integración o un cambio normativo, se publica una versión nueva del documento y se vuelve a parsear y a cargar en la base vectorial antes de anunciar el cambio a clientes.
Trimestral	Se revisan los logs de auditoría (Gmail) para detectar preguntas frecuentes sin cobertura, se recalibran Top-K y Minimum Score y se decide si conviene sumar un documento nuevo.

Criterios para eliminar o reemplazar un documento

- **Reemplazo:** cuando sale una versión nueva aprobada por la Gerencia Comercial. Se sube la nueva versión y se **elimina la anterior el mismo día**: nunca conviven dos versiones del mismo manual en el índice, para que el agente no mezcle precios viejos y nuevos.
- **Eliminación:** si el documento está vencido (pasó su fecha de revisión sin aprobarse), si describe un producto o plan discontinuado, si contradice a otro documento con mayor jerarquía, o si contiene datos personales o información confidencial que no debe exponerse al chat.
- **Re-procesamiento:** si la batería mensual baja del 80 % por fallas de recuperación (no de redacción), se re-parsea y se re-chunkea el documento antes de pensar en reemplazarlo.
- **Trazabilidad:** cada alta, baja o reemplazo se registra en un changelog (fecha, versión, responsable, motivo y resultado de la batería). Las versiones retiradas se archivan en Drive y nunca quedan cargadas en la base vectorial.